

Clasificación de Contaminantes en una Línea de Producción Simulada: Evaluación Comparativa de Algoritmos Clásicos

Daniel Esteban Valverde Ortiz (C28041)

Escuela de Ingeniería Eléctrica
Universidad de Costa Rica (UCR)
San Pedro, Costa Rica
IE0435 - Inteligencia Artificial

RESUMEN

Este documento explica el diseño, desarrollo y evaluación de un sistema de visión artificial y aprendizaje automático enfocado en el control de calidad industrial. El objetivo central es la clasificación y detección automática de elementos contaminantes (como clips o aros metálicos) frente a granos de arroz dentro de una línea de producción simulada. Se consolidó un conjunto de datos colaborativo de 120 muestras fotográficas, las cuales fueron estandarizadas mediante redimensionamiento espacial a 128×128 píxeles, conversión a escala de grises y binarización, transformándose finalmente en vectores de 16,384 características. Como parte de la validación experimental, se evaluaron cinco algoritmos clásicos de clasificación: Árboles de Decisión, Random Forest, Máquinas de Vectores de Soporte (SVM), K-Nearest Neighbors (KNN) y Naïve Bayes. Los resultados demostraron que, ante variaciones severas de escala e iluminación entre las muestras, el Árbol de Decisión resultó ser el modelo más eficiente, alcanzando una exactitud del 79.2 %. Se concluye que las estructuras de decisión lógicas basadas en la morfología binarizada permiten una mejor identificación de los defectos bajo las condiciones descritas.

Palabras Clave—Aprendizaje Automático, Árboles de Decisión, Control de Calidad, Visión por Computadora, Clasificación Binaria, Binarización.

I. INTRODUCCIÓN

En los procesos de manufactura contemporáneos, la inspección visual sistemática resulta crítica para la detección de anomalías y la garantía de calidad, reduciendo a su vez el margen de error humano. Con la consolidación de la inteligencia artificial, particularmente a través de algoritmos de aprendizaje automático (*Machine Learning*), es factible delegar dichas tareas a sistemas computacionales entrenados para reconocer características morfológicas en imágenes.

El presente proyecto aborda el desafío de diseñar un sistema de clasificación para identificar elementos contaminantes en una línea de procesamiento de granos. Utilizando un conjunto de fotografías capturadas de forma independiente por múltiples integrantes, se evalúa la eficacia de técnicas clásicas de clasificación

ante variaciones naturales de iluminación, perspectiva y encuadre. Se simula una línea sobre superficie blanca donde la clase positiva ('1') corresponde a granos de arroz y la clase negativa ('0') corresponde a objetos metálicos o ausencia de producto.

II. METODOLOGÍA

A. Adquisición y Consolidación de Datos

El conjunto de datos empírico se generó mediante una recolección colaborativa. Integrantes del curso proporcionaron fotografías individuales simulando la línea de producción. Mediante un proceso de integración (`unir_datasets.py`), se consolidaron cuatro conjuntos de datos para formar un repositorio maestro con 120 muestras.

Dada la heterogeneidad de las fuentes de captura, el dataset consolidado presentó desafíos inherentes como la inversión de la polaridad binaria en ciertas muestras (matrices de color invertido). Se aplicó una técnica de ingeniería de datos para corregir dichas inconsistencias ($1 - \text{píxel}$) y se imputaron las etiquetas faltantes. Adicionalmente, el ordenamiento de las filas se aleatorizó (*shuffle*) para evitar sesgos temporales o secuenciales en el entrenamiento.

B. Preprocesamiento de Imágenes y Vectorización

Para proveer a los modelos una entrada estructurada, se estableció un conducto de procesamiento utilizando la biblioteca OpenCV:

- **Redimensionamiento:** Todas las muestras se homogeneizaron a una resolución espacial de 128×128 píxeles, utilizando interpolación digital para regularizar variaciones de escala.
- **Umbralización (Binarización):** Se convirtieron las imágenes a escala de grises para luego aplicar un umbral que separa los objetos del fondo. La codificación resultante asignó el valor 1 al fondo (superficie de la línea) y 0 a los objetos detectados.
- **Aplanamiento (Flattening):** La matriz bidimensional de cada muestra se transformó en un arreglo unidimensional de longitud $L = 128 \times 128 = 16,384$ atributos.

C. Algoritmos de Clasificación Evaluados

Se evaluaron cinco algoritmos, fundamentados en la teoría y apuntes del curso IE0435:

1. **Árboles de Decisión:** Modelos que segmentan el espacio de características mediante reglas secuenciales.
2. **Random Forest:** Un ensamble estocástico de árboles de decisión que mejora la generalización.
3. **SVM Lineal:** Algoritmo de margen máximo para la búsqueda del hiperplano de separación óptimo.
4. **K-Nearest Neighbors (KNN):** Clasificación basada en la proximidad métrica en el espacio de dimensionalidad 16,384.
5. **Naïve Bayes (Gaussiano):** Clasificador probabilístico fundamentado en la suposición de independencia condicional entre características.

III. RESULTADOS Y DISCUSIÓN

A. Configuración Experimental

El modelo de evaluación dividió el dataset consolidado en dos subconjuntos: 80 % de muestras de entrenamiento (96 imágenes) y 20 % de pruebas (24 imágenes), aplicando un muestreo estratificado para mantener la representación de las clases. Se implementaron los modelos utilizando la librería `scikit-learn`. Con el objetivo de garantizar la repetitividad de los resultados, se fijó una semilla generadora en `random.state = 42`. Asimismo, se utilizó el ajuste de `class.weight = 'balanced'` en los algoritmos aplicables, obligando a los modelos a ponderar equitativamente los errores de detección de contaminantes y granos válidos.

B. Desempeño Comparativo

En la Tabla I se detalla el comportamiento de cada clasificador con respecto a su exactitud (Accuracy) porcentual medida en el conjunto de prueba.

Cuadro 1: Métricas de Exactitud en el Conjunto de Prueba

Algoritmo Evaluado	Exactitud (%)
Árbol de Decisión (Seleccionado)	79.2
Random Forest	70.8
Máquinas de Vectores de Soporte (SVM)	62.5
K-Nearest Neighbors (KNN)	62.5
Naïve Bayes (Gaussiano)	50.0

C. Análisis del Modelo Seleccionado

El Árbol de Decisión resultó ser el modelo superior para la segmentación del conjunto de datos binarizado (79.2 %). La superioridad empírica de este método sobre algoritmos como el SVM Lineal o el Naïve Bayes sugiere que la naturaleza de los descriptores espaciales generados en el preprocesamiento posee umbrales claros a nivel morfológico que un árbol de reglas jerárquicas puede aprovechar mejor que un análisis meramente probabilístico (Naïve Bayes, el cual sufre fuertemente por la asunción de independencia de píxeles adyacentes, reportando tan solo un 50.0 %).

Por otro lado, aunque típicamente el Random Forest (70.8 %) posee un menor sesgo, en esta instancia el tamaño reducido del conjunto de datos (120 muestras totales) permitió que el Árbol de Decisión individual aislara mejor las características discriminantes fundamentales sin el efecto "suavizador" de un ensamble que limitó la sensibilidad en variaciones locales.

IV. CONCLUSIONES Y RECOMENDACIONES

El abordaje del control de calidad industrial mediante la inteligencia artificial comprobó ser viable. Las tareas de ingeniería de características, en particular la binarización unificada (128×128) y la corrección de polaridades, mitigaron en gran medida el impacto de la captura heterogénea. El Árbol de Decisión se destacó como el mejor estimador, lo cual resalta la eficacia de reglas deterministas sobre el análisis puro de color binarizado.

Como recomendación a futuro, se propone la estandarización estricta del marco lumínico y un aumento sustancial de la base de datos para habilitar la aplicación de enfoques más robustos (como redes neuronales convolucionales) sin riesgo de sobreentrenamiento.

REFERENCIAS

- [1] M. Coto, *Notas de Clase IE0435: Inteligencia Artificial*. Escuela de Ingeniería Eléctrica, Universidad de Costa Rica, 2026.
- [2] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.